

## **Projet Dataiku : Scoring de crédit – Banque Américaine.**

Réalisé par : SKOURI Youssef.  
Année universitaire : 2025/2026

## Table de matières

|                                                                                                                                                                     |           |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>1ère partie : Source de données – Exploration des données.</b>                                                                                                   | <b>4</b>  |
| Question 1A : Quelle est la proportion d’individus ayant eu un incident ?                                                                                           | 5         |
| Question 1B : Quel est le montant global prêté pour les personnes n’ayant eu aucun incident de paiement ? (capture(s) d’écran + justifications requises)            | 6         |
| Question 1C : Quel est le type d’emploi qui possède, en moyenne, le plus de produits dans la banque ? (capture(s) d’écran + justifications requises)                | 8         |
| Question 1D : Discrétisez la variable DEBTINC par tranche de 5. Renommez-là DEBTINC_DISC. Combien de classes sont créées ? (capture(s) d’écran)                     | 9         |
| Question 1E : Analysez la matrice de corrélation de la base de données et concluez. (capture(s) d’écran + justifications requises)                                  | 10        |
| <b>2ème partie : Apprentissage supervisé</b>                                                                                                                        | <b>11</b> |
| Question 2A : Quelle variable allez-vous mettre en “Target” ? Pourquoi ?                                                                                            | 11        |
| Question 2B : Quel type de prédiction allez-vous réaliser ? Pourquoi ?                                                                                              | 11        |
| Etape 1 : Construisez un arbre de décision :                                                                                                                        | 13        |
| Question 2C : Combien de feuilles comporte l’arbre optimal ? (1 capture d’écran requise).                                                                           | 13        |
| Question 2D : Quelle variable est utilisée pour la 1ère scission ?                                                                                                  | 14        |
| Question 2E : Quelles variables étaient en compétition pour cette 1ère scission ? Justifiez l’ordre de ces variables (capture d’écran requise).                     | 14        |
| Question 2F : Ces modifications ont-elle amélioré la performance du modèle ? Justifiez. (captures d’écran requises)                                                 | 16        |
| Etape 2 : Construisez une forêt aléatoire :                                                                                                                         | 18        |
| Question 2G : Quelle variable est utilisée pour la 1ère scission ?                                                                                                  | 18        |
| Question 2H : Quelles variables étaient en compétition pour cette 1ère scission ? Justifiez l’ordre de ces variables (capture d’écran requise).                     | 18        |
| Question 2I : Quelle est la valeur de l’AUC et la forme de la courbe ROC ? Commentez. (capture d’écran requise).                                                    | 19        |
| Étape 3 : Construisez la régression logistique.                                                                                                                     | 19        |
| Question 2J : Quels sont les deux premières variables les plus importantes dans le modèle ? Interprétez leurs coefficients de régression (capture d’écran requise). | 19        |
| Étape 4 : Construisez le SVM.                                                                                                                                       | 20        |
| Question 2K : Qu’est-ce qu’un modèle SVM ? (sources obligatoires)                                                                                                   | 20        |
| Question 2L : les SVM sont-ils sensibles aux données manquantes ? Justifiez vous réponse par une illustration. (sources éventuelles obligatoires)                   | 21        |
| Question 2M : A quelle étape du protocole devrions-nous faire cette transformation de variables ? (capture d’écran requise). Justifiez.                             | 22        |

**Question 2N : Comment juger de l'impact de ces transformations ? (captures d'écran requises). Les SVM nécessitent-ils de transformer ces variables ? Justifiez votre réponse (capture d'écran requise et sources éventuelles obligatoires).....22**

**3ème partie : Validation du modèle et Scoring .....24**

**Question 3A : Compte tenu de la mesure d'évaluation la plus fréquemment utilisée, quels seraient le graphique et le(s) indicateur(s) le plus approprié pour choisir le modèle le plus performant ? Expliquez ce choix (capture d'écran requise et sources éventuelles obligatoires)..25**

**Question 3B : Quelle est la valeur du seuil optimal maximisant la métrique utilisée ? Quels seraient les impacts d'une modification de ce seuil ? (capture d'écran requise).....26**

**Question 3C : Le seuil proposé par l'outil est-il satisfaisant ? Expliquez pourquoi.....27**

**Question 3D : Interprétez la valeur de la colonne explanations pour le CustomerID n°A0112. ...28**

**Question 3E : Au vu des résultats de votre modèle et comparativement à la réalité, quelle conclusion pouvez-vous faire sur votre modèle ? Justifiez votre réponse par la construction, grâce à Dataiku, de tout élément utile à votre conclusion (captures d'écran requises).....28**

**4ème partie : Travail Personnel.....30**


**Feature engineering : .....30**

**Un nouveau modèle (XGBoost) .....32**

## 1ère partie : Source de données – Exploration des données.

Après importation des deux bases de données, on remarque que chacune contient 4871 lignes. La base hmeq contient les variables exogènes (explicatives) alors que la base incidente contient la variable endogène (expliquée). On remarque ainsi, que les deux tables peuvent être liées par la variable CustomerID.

On commence par effectuer la jointure entre les deux tables initiales et crée la table de sortie : hmeq\_joined.



**New join recipe**

**Input datasets**

- hmeq (DATASET - View)
- incident (DATASET - View)

Additional inputs can be added after the recipe creation.

**Output dataset**


Name: hmeq\_joined

Store into: filesystem\_managed

Format: CSV

NEW DATASET | USE EXISTING DATASET

CANCEL CREATE RECIPE



Le type de jointure effectué est un Inner join pour ne garder que les lignes (CustomerID) figurant dans les deux tables. On choisit ainsi 'Send unmatched rows to other output dataset' pour créer une base de données des lignes qui ne figurent pas dans les deux bases initiales.




On remarque qu'une seule table était créée. Donc, tous les IDs des tables sont liés (match).

### Question 1A : Quelle est la proportion d'individus ayant eu un incident ?

Pour répondre à la question, on calcule une table de fréquences pour la variable 'BAD' en appliquant un filtre sur la variable 'VALUE' pour ne garder, comme l'énoncé l'indique, que les dossiers ayant indiqué une valeur de propriété.

Donc, sur l'onglet Statistics, on choisit Univariate Analysis. Et on choisit la variable 'BAD' comme variable à décrire.



La prochaine étape est de choisir la condition en dessous pour le Sampling and filtering. Ce qui permet de garder seulement les dossiers avec une valeur de propriété déjà définie (non vide).

Edit filter

Keep only rows that satisfy

the following conditions

Where

VALUE

Is defined

...

+ ADD A CONDITION

▼

CANCEL

APPLY

**Résultat :** Table de fréquences.

| ▼ A BAD           |     |      | 🗑️ ⋮ |
|-------------------|-----|------|------|
| ▼ Frequency table |     |      |      |
| 0                 | 82% | 3901 |      |
| 1                 | 18% | 877  |      |
| N distinct        |     |      | 2    |

Donc, la proportion des individus ayant eu un incident est 18%. Vu que la classe (1) correspond à l'occurrence d'un incident.

**Question 1B :** Quel est le montant global prêté pour les personnes n'ayant eu aucun incident de paiement ? (capture(s) d'écran + justifications requises)

On répond à cette question par un histogramme ayant la variable 'LOAN' par la variable 'BAD'. On note que cela se fait sur l'onglet *Charts* et qu'il faut choisir comme Agrégation pour la variable 'LOAN' ; SUM.

De plus, on applique un filtre sur la variable 'VALUE' pour ne pas considérer les cases vides.


▼ Filters
 4778/4871 records

▼ VALUE
 ⋮



8000
 855909

☐ Include empty values



Donc, le montant total prêté aux personnes n'ayant eu aucun incident est 74.17M \$

**Remarque :** si on veut voir le montant exacte, on choisit *None* pour le *Multiplier* sur les options *Data labels*:

Data labels

< LOAN (SUM) >

Numbers

Impacts tooltips and values displayed in charts

☐ Display as percentage

☐ Use parenthesis for negative values

Prefix

Suffix

None

None

Multiplier

Auto

Auto

None

Thousands

Millions (M)


Millions (m)

Billions (B)

Billions (G)

☐ APPLY TO AXIS


> Text



Donc, le montant total est exactement 74 167 300 \$

**Question 1C :** Quel est le type d'emploi qui possède, en moyenne, le plus de produits dans la banque ? (capture(s) d'écran + justifications requises)

On suit la même logique qu'auparavant (onglet Charts et filtre appliqué sur VALUE) , sauf que maintenant on a la variable CLNO en Y ( avec une agrégation AVG) et la variable 'JOB' en X.



Sales est le type d'emploi possédant en moyenne le plus de produits en banque. Avec une moyenne de 25.05.

**Question 1D :** Discrétisez la variable DEBTINC par tranche de 5. Renommez-là DEBTINC\_DISC. Combien de classes sont créées ? (capture(s) d'écran)

On ajoute une Recipe au Workflow, on sélectionne la méthode Bin et on choisit Bins width = 5

De plus, on supprime les lignes ayant pas de valeur pour la variable 'VALUE'.

Bin values in DEBTINC

4871

Input column

DEBTINC

Binning mode

Fixed size intervals

Bins width

5

☐ Use minimum value

☐ Use maximum value

Output column (empty for in-place)

DEBTINC\_DISC

Remove rows where VALUE is not a valid

Decimal

93

Action

Remove invalid rows

Column

single | multiple | pattern | all

VALUE

Meaning to check

Decimal

☒ Consider empty cells as invalid

Une analyse univarié nous permet d'affirmer que le nombres des classes créées est 20.

**Remarque :** le tableau indique 21 classes car il prend en compte aussi en compte les cases vides et les regroupe en une classes 'No Value'

### ▼ Summary stats

|            |         |
|------------|---------|
| N values   | 4778    |
| N distinct | 21      |
| Mode       | 35 : 40 |
| N empty    | 970     |

**Question 1E :** Analysez la matrice de corrélation de la base de données et concluez.  
(capture(s) d'écran + justifications requises)


Avant de visualiser la matrice de corrélation, on s'assure que les types de stockages des variables sont correctes. Donc, dans la recipe précédente, on change manuellement les types de stockages.

**Exemple :**

|            |         |         |         |        |        |         |         |         |         |         |         |         |        |
|------------|---------|---------|---------|--------|--------|---------|---------|---------|---------|---------|---------|---------|--------|
| CustomerID | LOAN    | MORTDUE | VALUE   | REASON | JOB    | YOJ     | DEROG   | DELINQ  | CLAGE   | NINQ    | CLNO    | DEBTINC | DEBTI  |
| string     | int     | double  | double  | string | string | double  | int     | int     | double  | int     | int     | string  | string |
| Text       | Integer | Decimal | Decimal | Text   | Text   | Decimal | Integer | Integer | Decimal | Integer | Integer | Decimal | Text   |

**Remarque :** un type de stockage erroné peut influencer le calcul des corrélations et aussi les prochaines modélisations statistiques.

Pour calculer les corrélations, dans l'onglet Statistics, on choisit Multivariate Analysis, puis Correlation Matrix et on sélectionne les variables numériques présentes sur notre table



On remarque une très forte corrélation entre les deux variables 'MORTDUE' et 'VALUE' de 0.860. Ce qui est logique car la première variable est le montant de l'hypothèque et la deuxième est la valeur du propriété. Plus cette valeur augmente plus l'hypothèque dessus tend à être élevée.

**NB :** Cette forte corrélation va sûrement influencer négativement les modélisations futures, car on aura une redondance d'information (problème de multicollinéarité).

Dans un tel cas, on sera amené à garder qu'une seule variable en se basant sur des métriques statistiques. VIF par exemple.

On remarque aussi des corrélations remarquables mais pas inquiétantes, entre VALUE et CLNO et VALUE et LOAN.

## 2ème partie : Apprentissage supervisé

**Question 2A :** Quelle variable allez-vous mettre en "Target" ? Pourquoi ?

La variable Target sera la variable 'BAD' car c'est la variable endogène qu'on cherche à expliquer vu qu'elle indique l'occurrence ou non de l'incident (le défaut bancaire).

**Question 2B :** Quel type de prédiction allez-vous réaliser ? Pourquoi ?

Le type de prédiction est une classification binaire. Car, la variable cible est une variable catégorielle à deux modalités (0/1)

Avant de passer aux modélisations. Premièrement, on commence par une Recipe pour supprimer la variable DEBTINC\_DISC.

La table actuelle est : hmeq\_joined\_prepared\_prepared

Remove DEBTINC\_DISC

4778

Column

single | multiple | pattern | all

DEBTINC\_DISC

☒ Remove

☐ Keep

X<sup>2</sup>

i

💬

📄

?

Deuxièmement, on sélectionne la Recipe LAB, AutoML Prediction.

Create prediction model on BAD ▾

AutoML

Let Dataiku create your models.

Quick Prototypes

Get some models, generic and quick.

In-memory ▾

Interpretable Models for Business Analysts

Start with decision tree and simple linear models.

High Performance Models

Be patient and get even more accurate models.

Expert

Have full control over the creation of your models.

Deep Learning

Create the architecture of your deep learning models and train them.

Choose Algorithms

Select the algorithms and the hyper parameters to use in cross-validation.

Write Your Own Estimator

Train your own Python or Scala models.

>>> clf = MyAlgo()

Name your analysis

Quick modeling of BAD on hmeq\_joined\_prepared\_prepared

CREATE

On choisit la variable 'BAD' comme variable à prédire et on choisit l'option Choose Algorithms. À ce stade, on sélectionne les quatre types de modèles suggérés par l'énoncé.

12

|                       |                                        |
|-----------------------|----------------------------------------|
| Random Forest         | <input checked="" type="checkbox"/> ON |
| Gradient tree boos... | <input type="checkbox"/> OFF           |
| Logistic Regression   | <input checked="" type="checkbox"/> ON |
| LightGBM              | <input type="checkbox"/> OFF           |
| XGBoost               | <input type="checkbox"/> OFF           |
| Decision Tree         | <input checked="" type="checkbox"/> ON |
| Support Vector Ma...  | <input checked="" type="checkbox"/> ON |


Sur la page DESIGN on impose les conditions suivantes : No sampling (whole data), Train ratio 0.6 et la valeur de seed 2903. Ensuite, on clique sur le bouton TRAIN.

### Etape 1 : Construisez un arbre de décision :

**Question 2C :** Combien de feuilles comporte l'arbre optimal ? (1 capture d'écran requise).

Dans l'onglet EXPLAINABILITY du modèle Arbre de décision on peut visualiser l'arbre complète.

Decision tree



Le nombre des feuilles est 26.

**Question 2D :** Quelle variable est utilisée pour la 1ère scission ?

La première scission se fait sur la variable  $DEBTINC > 33.57$  donc c'est la variable DEBTINC qu'est utilisée pour la première scission.

**Question 2E :** Quelles variables étaient en compétition pour cette 1ère scission ? Justifiez l'ordre de ces variables (capture d'écran requise).

Toujours dans la section EXPLAINABILITY, on visualiser le graphique Feature Importance.

**Remarque :** avant de passer à la visualisation, on note que c'est le critère GINI qu'on doit choisir. Comme on peut constater sur MODEL INFORMATION, Algorithm. GINI est le critère des splits.


## Algorithm details

| Algorithm            | Decision tree classifier |
|----------------------|--------------------------|
| Max tree depth       | 5                        |
| Split criterion      | <b>gini</b>              |
| Min samples per leaf | 1                        |
| Splitter             | <b>best</b>              |

Feature importance

SHAPLEY GINI

Variable importance



Toutes les variables explicatives étaient en compétition, le graphique omette quelques unes car elles ont une importance de 0%. Néanmoins, pour justifier l'ordre qu'on vient de visualiser. L'indice GINI est une mesure de réduction d'impureté apportée par chaque variable, donc, une variable est mieux classée si elle nous permet d'avoir des noeuds qui sont le plus purs

possible (le moindre mélange entre les classes). Sur le graphique précédent, on remarque que la variable 'DEBTIN' domine largement avec 78%. Ce qui est en parfait accord avec le fait qu'elle soit la variable de la première scission. Les autres variables interviennent dans des ordres décroissant dans notre arbre sur des échantillons plus petits, pour cela, elles ont une importance décroissante.

*Construisez un deuxième arbre en ajoutant une profondeur maximale à 10 et à 20, en utilisant le critère d'Entropy comme mesure du split et en utilisant une stratégie de split aléatoire.*

**Question 2F :** Ces modifications ont-elle amélioré la performance du modèle ? Justifiez. (captures d'écran requises)

Revenons à l'onglet DESIGN, puis Algorithms et modifions les paramètres comme demandé dans l'énoncé.

**Decision Tree** ON

Decision Tree is a simple non-parametric algorithm. It creates a model that predicts the value of the target by learning simple decision rules inferred from the data features.  
[Show more...](#)

Maximum depth

10 ✕ 20 ✕

The maximum depth of the tree.

Criterion

☐ Try Gini

☒ Try Entropy

The function to measure the quality of a split. Supported criteria are "gini" for the Gini impurity and "entropy" for the information gain.

Min. samples per leaf

1 ✕

Minimum number of samples required to be at a leaf node.

Split strategy

☐ Try Best

☒ Try Random

The strategy used to choose the split at each node. Supported strategies are "best" to choose the best split and "random" to choose the best random split.

 Training models

1 model will be trained on 12 features  
An estimated total of 11 estimators will be evaluated.

**Session Name & Description**

Name

Description

**Train & test**

Train (2850 rows) and test (1928 rows) sets computed on 2026/05/24-18:08 will be used.

☐ Drop existing sets, recompute new ones

× CANCEL    ▶ TRAIN

On peut affirmer que ces modifications n'ont pas amélioré les performances du modèle. Car, on se basant sur le critère de AUC. On a  $AUC = 0.861$  (pour l'arbre initial) et  $AUC(\text{Deuxième modèle}) = 0.791$ .


| Previously trained       |                                                                                                                          |                                                                                     |       |                                                                                       |
|--------------------------|--------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------|---------------------------------------------------------------------------------------|
| <input type="checkbox"/> | ARBRE-MODIFICATIONS                                                                                                      |                                                                                     |       |                                                                                       |
| <input type="checkbox"/> |  Decision Tree (Arbre-Modifi...       |  | 0.791 |  |
| <input type="checkbox"/> | PREMIER TRAINING                                                                                                         |                                                                                     |       |                                                                                       |
| <input type="checkbox"/> |  Random forest (Premier trai...       |  | 0.950 |  |
| <input type="checkbox"/> |  Logistic Regression (Premier trai... |                                                                                     | 0.785 |  |
| <input type="checkbox"/> |  Decision Tree (Premier training)     |                                                                                     | 0.861 |  |
| <input type="checkbox"/> |  SVM (Premier training)               |                                                                                     | 0.862 |  |

**Explication :** Cette perte de performances est assez logique car on a choisi une profondeur assez grande, donc on peut suspecter un problème d'Over-fitting. Et, on a choisi un split 'random' au lieu de best. Donc, au lieu de choisir la meilleure scission à chaque nœud, on découpe d'une manière aléatoire.

## Etape 2 : Construisez une forêt aléatoire :

### Question 2G : Quelle variable est utilisée pour la 1ère scission ?

On ne peut pas cette fois répondre à cette question en se basant sur la visualisation de l'arbre comme on a fait pour Decision Tree précédemment. Car, on sait que Random Forest est une multitude d'arbres et non pas qu'une seule. Pour cela, on se basera sur la Feature Importance.



La variable la plus importante est DEBTINC. On affirme que c'est la variable utilisée pour la première scission. Mais, bien évidemment, pas nécessairement dans TOUTES les arbres du Random Forest. C'est juste, la variable la plus dominante.

### Question 2H : Quelles variables étaient en compétition pour cette 1ère scission ? Justifiez l'ordre de ces variables (capture d'écran requise).


On inclut pas de capture d'écran pour cette réponse car on se base sur le précédent capture. Pour les mêmes raisons déjà expliqué pour la Decision Tree, on a la variable DEBTINC comme la plus importante (capacité à trancher des noeuds purs) suivie de DELINQ est CLAGE, qui s'appliquent sur des échantillons plus petits.

**Question 2I :** Quelle est la valeur de l'AUC et la forme de la courbe ROC ? Commentez. (capture d'écran requise).

On peut voir la valeur de AUC directement sur RESULTS. Ou on peut aussi la lire sur l'onglet PERFORMANCE (ROC & PR curves) à droite de la courbe ROC.

La valeur du AUC est 0.95 et la forme de la courbe n'est pas trop éloigné d'une courbe parfaite (un angle de 90 degrés sans inclinaison).


Ces deux métriques nous permettent d'affirmer que ce modèle arrive à bien séparer entre les deux modalités de la variable endogène 'BAD'.



**Étape 3 : Construisez la régression logistique.**

**Question 2J :** Quels sont les deux premières variables les plus importantes dans le modèle ? Interprétez leurs coefficients de régression (capture d'écran requise).

La section Feature Importance montre que les deux premières variables les plus importantes sont DELINQ et CLAGE.



Pour trouver les coefficients, la section Regression Coefficient.

|        |         |  |
|--------|---------|--|
| CLAGE  | -0.0050 |  |
| DELINQ | 0.8100  |  |

### Interprétation :

Le coefficient de 0.81 pour la variable DELINQ indique qu'une augmentation unitaire de cette variable (donc un litige supplémentaire) augmente la cote d'incident par  $e^{0.81} = 2.25$ . Donc, à chaque litige supplémentaire, la personne est 2.25 fois plus susceptible d'avoir un incident.

Le coefficient de  $-0.005$  indique que chaque mois d'ancienneté de plus du crédit multiplie la cote d'incident par  $e^{-0.005}$ , donc une diminution de 0.5% du risque.

## Étape 4 : Construisez le SVM.

### Question 2K : Qu'est-ce qu'un modèle SVM ? (sources obligatoires)

Le SVM (Support Vector Machine) est un algorithme de machine learning supervisée (donc utilisant des données libellées) qu'on utilise pour les problèmes de classification. Le principe fondamental c'est de chercher un hyperplan optimal qui sépare les points (les deux classes). Donc un type de frontière qui maximise la marge entre les points des deux classes. Dans plusieurs cas, on n'arrive pas à séparer linéairement entre les deux classes, d'où on trouve des

méthodes polynomiales ou on fait recours à une projection dans un espace de dimension supérieure ou une séparation linéaire peut être envisageable.

**On cite l'article fondateur des SVM : Cortes, C. & Vapnik, V. (1995). Support-Vector Networks, Machine Learning**

**Question 2L : les SVM sont-ils sensibles aux données manquantes ? Justifiez vous réponse par une illustration. (sources éventuelles obligatoires)**

Les SVM sont sensibles aux données manquantes ils reposent sur le calcul des distances et de produits scalaires entre les observations (les points) pour déterminer l'hyperplan séparateur. Donc si une observation a une coordonnée manquante (donc une valeur d'une variable qui manque) ce calcul des distances devient impossible. Pour cela, il faut qu'on impute les valeurs manquantes avant l'entraînement d'un SVM.

Dans le cas de notre SVM. On donne l'exemple de la variable 'DEBTINC' qui a 21.3% de valeurs manquantes. Sans traitement de ces valeurs on n'auraient pas pu entraîner le SVM (car impossible de calculer les distance). Pour cela, Dataiku a fait automatiquement une imputation par la moyenne.

Handling of **DEBTINC**

Role

☐ Reject  
☒ Input

Variable type

☐ A Categorical  
☒ # Numerical  
☐ I Text  
☐ [ ] Vector  
☐ Image

Numerical handling

Keeping as a regular numerica

Rescaling

Standard rescaling

Make derived feats.

☐ Generate sqrt(x), x^2, ... features

Missing values

Impute ...

Impute with

Average of values

**Source : on cite Hsu, Chang & Lin (2003), Source de l'article :**  
<https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>

**Question 2M :** A quelle étape du protocole devrions-nous faire cette transformation de variables ? (capture d'écran requise). Justifiez.

On fait cette transformation à travers le Features Handling ou par Recipe. Avant de passer à l'entraînement des modèles. Car, une telle transformation modifiera la distribution des variables, donc, il faut l'appliquer avant que les modèles n'apprennent sur ces données.

**Question 2N :** Comment juger de l'impact de ces transformations ? (captures d'écran requises). Les SVM nécessitent-ils de transformer ces variables ? Justifiez votre réponse (capture d'écran requise et sources éventuelles obligatoires).

Premièrement, on identifie les variables fortement asymétriques : LOAN, MORTDUE, VALUE, YOJ. Les variables de comptage ne seront pas affectées par une transformation log car les distribution ne sont pas vraiment étalée.

On ajoute une nouvelle Recipe et on crée les variables transformées. En dessous un exemple

Formula for


`log(LOAN)`

Formula is valid ✓

| Sample output      | LOAN |
|--------------------|------|
| 3.041392685158225  | 1100 |
| 3.113943352306837  | 1300 |
| 3.1760912590556813 | 1500 |
| 3.230448921378274  | 1700 |
| 3.255272505103306  | 1800 |
| 3.3010299956639813 | 2000 |
| 3.3010299956639813 | 2000 |
| 3.3010299956639813 | 2000 |
| 3.3010299956639813 | 2000 |

**Remarque :** pour Yoj on applique une transformation  $\log(1+x)$  car cette variable a pour minimum la valeur 0.

À cette étape on a le Workflow suivant :



Ensuite, on crée un nouveau LAB avec les mêmes paramètres d'avant : 0,6 split, no sampling, random seed à 2903.

La prochaine étape est de désélectionner les variables originales et garder les variables transformées.

|                                       |                                  |                                        |
|---------------------------------------|----------------------------------|----------------------------------------|
| <input checked="" type="checkbox"/> # | LOAN<br>Reject                   | <input type="checkbox"/> OFF           |
| <input type="checkbox"/> #            | Log_loan<br>Avg-std rescaling    | <input checked="" type="checkbox"/> ON |
| <input type="checkbox"/> #            | MORTDUE<br>Reject                | <input type="checkbox"/> OFF           |
| <input type="checkbox"/> #            | Log_MORTDUE<br>Avg-std rescaling | <input checked="" type="checkbox"/> ON |
| <input type="checkbox"/> #            | VALUE<br>Reject                  | <input type="checkbox"/> OFF           |
| <input type="checkbox"/> #            | Log_value<br>Avg-std rescaling   | <input checked="" type="checkbox"/> ON |
| <input type="checkbox"/> A            | REASON<br>Dummy encoding         | <input checked="" type="checkbox"/> ON |
| <input type="checkbox"/> A            | JOB<br>Dummy encoding            | <input checked="" type="checkbox"/> ON |
| <input type="checkbox"/> #            | YOJ<br>Reject                    | <input type="checkbox"/> OFF           |

Après entraînement on a un modèle SVM avec un AUC de 0.868. Donc, une valeur de AUC supérieur au modèle précédent qu'était 0.862.

|                                           |       |                                      |                                       |                                     |
|-------------------------------------------|-------|--------------------------------------|---------------------------------------|-------------------------------------|
| <input type="checkbox"/> SVM (svm-second) |       | 0.868                                | ✓ Done just now (2026-05-24 23:01:45) | ☆ ⋮                                 |
| Kernel                                    | rbf   | No model-specific details available. | Train set                             | 2850 rows                           |
| C                                         | 1.0   |                                      | Test set                              | 1928 rows <a href="#">OPEN &gt;</a> |
| Gamma                                     | scale |                                      | Train time                            | about 4 seconds                     |

Cette transformation n'était pas nécessaire pour le SVM (différence minime de 0.006) est cela est du au fait que le prétraitement nécessaire pour les SVM n'est pas les transformation log. Mais, la mise en échelle car les SVM repose sur le calcul des distances pour déterminer les frontières de séparation entre classes.

**On recite :** Hsu, Chang et Lin (2003) recommandent dans leur guide de standardiser les variables avant d'entraîner un SVM, afin d'éviter que les variables d'amplitude élevée ne dominant celles d'amplitude plus faible dans le calcul de l'hyperplan. Ce rescaling (Avg-std) étant déjà appliqué dans notre modèle.

**Source de l'article :** <https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>

### 3ème partie : Validation du modèle et Scoring

**Remarque :** Dans cette partie, je vais répondre en se basant sur mon dernier rapport de stage effectué au sein d'une banque et qu'avait comme projet : Développement de scorecards pour l'octroi de crédits à la consommation. Donc, j'évoquerai les différents problèmes liés au scoring du défaut bancaire. Je citerai aussi les diverses sources utilisées pour l'élaboration de ce projet.

**Question 3A :** Compte tenu de la mesure d'évaluation la plus fréquemment utilisée, quels seraient le graphique et le(s) indicateur(s) le plus approprié pour choisir le modèle le plus performant ? Expliquez ce choix (capture d'écran requise et sources éventuelles obligatoires).

Premièrement, pour les modèles de classification binaire, les mesures les plus utilisées sont le AUC (Area Under Curve) le tracé de la courbe ROC. AUC est une métrique indépendante du seuil du décision et robuste au déséquilibre des classes. Contrairement à la précision qui est trompeuse dans ce cas.

On a évoqué le déséquilibre des classes car notamment dans les problèmes de scoring de défaut, le problème de déséquilibre des classes est toujours présent, ce qui mène dans plusieurs cas à effectuer des rééquilibrage : diminution des observations de la classes majoritaire (avec un risque de perte d'information) ou augmentation des observations de classe minoritaire (avec des observations synthétiques).

Deuxièmement, il convient ainsi de noter que c'est à la banque d'arbitrer le seuil de décision optimal selon le taux de risque qu'elle accepte. En abaissant le seuil elle détecte plus de mauvais payeurs mais risque de refuser des bons clients. Au contraire, en relevant le seuil elle accepte plus de client mais bien évidemment s'expose au risque d'accepter des mauvais clients.

**Source :** Stéphane Tufférey, *DATA MINING AND STATISTICS FOR DECISION MAKING*, 2011.

Dans notre cas, pour choisir le meilleur de nos modèles, on se basera sur l'AUC pour comparer. Comme le montre l'image suivante, Random Forest a la plus grande valeur (0.950).

|                          |                                      |                                                                                         |                                                                                     |
|--------------------------|--------------------------------------|-----------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|
| <input type="checkbox"/> | <b>PREMIER TRAINING</b>              |                                                                                         |                                                                                     |
| <input type="checkbox"/> | ● Random forest (Premier tr...       |  0.950 |  |
| <input type="checkbox"/> | ● Logistic Regression (Premier tr... | 0.785                                                                                   |  |
| <input type="checkbox"/> | ● Decision Tree (Premier training)   | 0.861                                                                                   |  |
| <input type="checkbox"/> | ● SVM (Premier training)             | 0.862                                                                                   |  |

Question 3B : Quelle est la valeur du seuil optimal maximisant la métrique utilisée ? Quels seraient les impacts d'une modification de ce seuil ? (capture d'écran requise)

Pour répondre à cette question. Faut d'abord qu'on sélectionne notre meilleur modèle (Random Forest) et puis on DEPLOY. Puis, on importe la base dmahmeq.csv sur le FLOW et on effectue les mêmes transformations : sélection des types de stockage et filtrage sur les lignes ayant une valeur non vide pour VALUE.

On sélectionne la RECIPES SCORE et on a choisi la base dmahmeq\_prepared

 Score a dataset

| ↶ Input dataset                                                    | ↶ Output dataset                                             |
|--------------------------------------------------------------------|--------------------------------------------------------------|
| Input dataset<br>dmahmeq_prepared<br><small>DATASET - View</small> | Name<br><input type="text" value="dmahmeq_prepared_scored"/> |
| Prediction Model<br>Predict BAD (binary)                           | Store into<br>filesystem_managed                             |
|                                                                    | Format<br>CSV                                                |
| <small>NEW DATASET   USE EXISTING DATASET</small>                  |                                                              |
| <div>           CANCEL           CREATE RECIPE         </div>      |                                                              |

La prochaine page nous indique que le seuil optimal proposé est de 0.350.


Threshold

Threshold

☒ Use threshold from the current version of the model (0.350)
 ☐ Override the threshold from the model

Comme indiqué précédemment, en abaissant ce seuil, le modèle classerait davantage des clients comme risqués, ce qui permet de détecter plus de mauvais vlient mais au détriment de refuser plus de bon client. En le relevant, le modèle fera l'inverse.

On peut voir dans l'onglet PERFORMANCE, Confusion matrix voir ce que la modification du seuil optimal apporte comme changement sur les différentes métriques.



### Question 3C : Le seuil proposé par l'outil est-il satisfaisant ? Expliquez pourquoi.

Ce seuil est optimal si on se limite à un point de vue statistique et qu'on a pour but la maximisation du f1-score. Mais le problème réside dans le fait qu'on traite les faux positifs et faux négatifs de la même façon alors qu'ils n'ont pas les mêmes conséquences dans un modèle de scoring bancaire. Un faux négatif est un mauvais client qu'on a accepté, donc un client qui va faire perdre à la banque le montant prêté, alors qu'un faux positif représente un manque à gagner. Dans le cas classique, les banques ont une tendance à baisser ce seuil de plus car elles visent une politique restrictive et préfèrent de mieux détecter les mauvais payeurs. Mais au final, on note que l'ajustement d'un tel seuil dépend fortement de la politique de la banque et les cycles macro-économiques qu'un pays traverse.

### Question 3D : Interprétez la valeur de la colonne explanations pour le CustomerID n°A0112.

On accède à la table dmahmeq\_prepared\_scored et on filtre sur Explore la variable CustomerID pour isoler la ligne de A0112 et on lit la valeur de la colonne explanation.

| proba_0            | proba_1             | prediction        | explanations                                       |
|--------------------|---------------------|-------------------|----------------------------------------------------|
| double<br>Decimal  | double<br>Decimal   | string<br>Integer | string<br>Object                                   |
| 0.8846102889442947 | 0.11538971105570546 | 0                 | {"VALUE": -0.49274652328056745, "LOAN": -0.5734... |

On a le JSON suivant :

```
{"VALUE": -0.49274652328056745, "LOAN": -0.5734889543275572, "DEBTINC": -1.1379009735369818}
```

Pour ce client, le modèle prédit qu'il appartient à la classe 0 (pas d'incident) avec une probabilité de 88.5%.

La colonne explanation nous donne les trois variables les plus influentes pour cette prédiction. Leurs trois poids sont négatifs, ce qui signifie qu'ils mènent la prédiction vers la classe 0. DEBTINC, est le facteur le plus influent et qui est un ratio dette/revenu faible de 23.58 pour ce client.

**Question 3E :** Au vu des résultats de votre modèle et comparativement à la réalité, quelle conclusion pouvez-vous faire sur votre modèle ? Justifiez votre réponse par la construction, grâce à Dataiku, de tout élément utile à votre conclusion (captures d'écran requises).

On importe la table incident\_results.xlsx et on effectue une jointure entre cette table et la table dmahmeq\_prepared\_scored (un inner join) basé sur CustomerID. La table résultante est : dmahmeq\_prepared\_scored\_joined.

Sur Charts de cette table crée. On crée un tableau croisé (Pivot Table) comme suivant :

|         |                  |
|---------|------------------|
| Rows    | BAD              |
| Columns | prediction       |
| Value   | Count of records |

## Count by prediction and BAD

| BAD                | prediction |            | Grand Total |
|--------------------|------------|------------|-------------|
|                    | 0          | 1          |             |
| 0                  | 804        | 59         | 863         |
| 1                  | 33         | 174        | 207         |
| <b>Grand Total</b> | <b>837</b> | <b>233</b> | <b>1070</b> |

**Rappel** : Prédiction est le résultat du scoring du modèle et la variable BAD vient de la nouvelle table des résultats réelle.

Ce tableau croisé représente notre matrice de confusion en se basant sur laquelle on peut calculer les différentes métriques.

D'abord on a :

Les vrais négatif = 804. Vrais positifs (VP) = 174. Faux positifs (FP) = 59. Faux négatifs (FN) = 33.

D'où on peut calculer les métriques :

$$Accuracy = (804 + 174)/1070 = 91.4\%$$

$$Précision \text{ (pour la classe 1)} = 174/233 = 74.7\%$$

$$Rappel \text{ (classe 1)} = 174/207 = 84.1\%$$

$$Spécificité = 804/863 = 93.2\%$$

On peut affirmer que le modèle généralise bien sur la nouvelle base de données. Avec une accuracy de 91.4%, un rappel de 84.1% (sur la classe incident) et une précision de 74.7%. Le modèle arrive à identifier correctement la grande majorité des clients et notamment 84% des mauvais client, ce qui montre qu'on n'a pas un problème d'over-fitting.

Pourtant on a 33 (FN) qui sont des erreurs qui peuvent être coûteuses pour la banque, car elles correspondent à des prêts qui ne seront pas remboursés. Pour pallier à ce risque, la banque peut envisager de réduire le seuil de décision (comme expliqué au début de cette partie).

## 4ème partie : Travail Personnel

Actuellement, notre meilleur modèle est le Random Forest avec un AUC de 0.950. Pour essayer de trouver un meilleur modèle, on va essayer deux pistes. Premièrement, le Feature Engineering, Deuxièmement, un nouveau modèle (XGBoost).

## Feature engineering :

On crée deux variables de ratios. Le LTV (LOAN/VALUE) qui est l'indicateur de risque le plus utilisé en credit scoring. Mesurant à quel point le client emprunte par rapport à la valeur de son bien. Logiquement, un ratio élevé traduit un prêt trop risqué avec peu de garanties par rapport au montant emprunté. Ensuite, on crée aussi un ratio MORT\_VALUE\_ratio (MORTDUE/VALUE) mesurant le taux d'endettement hypothécaire. En d'autres termes, combien il reste à payer sur l'hypothèque par rapport à la valeur du bien.

Pour cela, on applique une RECIPE prepare sur la base de données de l'entraînement hmeq\_joined\_prepared\_prepared et on aura notre nouvelle base incluant les variables ratios Piste1-ratios.

Create column **LTV** with formula **LOAN/VALUE**

4778

Output column

LTV

Expression

LOAN/VALUE

OPEN EDITOR PANEL

Error column

Create column **MORT\_VALUE\_ratio** with formula **MORTDUE/VALUE**


4392

Ensuite, dans un nouveau LAB on relance les 4 modèles en appliquant les mêmes conditions d'avant (split, seed fixé et pas de sampling).

| Previously trained       |                                                                                                                           |                                                                                           |                                                                                      |  |
|--------------------------|---------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--|
| <input type="checkbox"/> | RATIOS FIRST TRAIN                                                                                                        |                                                                                           |                                                                                      |  |
| <input type="checkbox"/> |  Random forest (RATIOS FIRST TR...       |  0.955 |   |  |
| <input type="checkbox"/> |  Logistic Regression (RATIOS FIRST TR... | 0.786                                                                                     |   |  |
| <input type="checkbox"/> |  Decision Tree (RATIOS FIRST TRAIN)      | 0.859                                                                                     |   |  |
| <input type="checkbox"/> |  SVM (RATIOS FIRST TRAIN)               | 0.861                                                                                     |  |  |

L'AUC du nouveau Random Forest est maintenant de 0.955. Donc une hausse de 0.005, une hausse légère mais c'est à la Feature Importance de confirmer si c'est une hausse réelle.

#### Variable importance



On remarque que LTV et MORT\_VALUE\_ratio on réellement contribuer avec 5% pour chacun. Donc, elles ajoutent vraiment un angle que les autres variables explicatives ne capturaient pas.

### Un nouveau modèle (XGBoost)

Dans le même LAB, sur onglet DESIGN, on ajoute l'algorithme XGBoost et on l'entraîne.

|                          |                                                                                                            |                                                                                          |                                                                                     |
|--------------------------|------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|
| <input type="checkbox"/> | <b>SESSION 2</b>                                                                                           |                                                                                          |                                                                                     |
| <input type="checkbox"/> |  Random forest (s2)       |  0.955 |  |
| <input type="checkbox"/> |  Logistic Regression (s2) | 0.786                                                                                    |  |
| <input type="checkbox"/> |  XGBoost (s2)             | 0.913                                                                                    |  |
| <input type="checkbox"/> |  Decision Tree (s2)       | 0.859                                                                                    |  |
| <input type="checkbox"/> |  SVM (s2)                 | 0.861                                                                                    |  |

Inhabituellement, XGBoost avec un AUC de 0.913 ne dépasse pas Random Forest. Mais, on peut expliquer cela par le fait qu'il est un algorithme très sensible aux hyperparamètres et donc une amélioration possible nécessitera un réglage de ces derniers. Finalement à ce stade, on gardera le Random Forest avec ratios (AUC=0.955).